Modelação e Previsão do Índice de Ações da Noruega: Uma Abordagem Comparativa entre SARIMAX, VAR e Redes Neuronais Recorrentes (LSTM)

André Marques, Afonso Claudino
Mestrado em Ciência de Dados
Instituto Universitário de Lisboa (ISCTE-IUL)
diana.mendes@iscte-iul.pt

31 de maio de 2026

Resumo

Este trabalho apresenta um estudo empírico sobre a modelação e previsão do índice de ações da Noruega (*Share Price Index*), integrando a sua relação macrofinanceira com o preço do Petróleo Brent e a taxa de câmbio USD/NOK no período entre 1992 e 2026. Sendo a Noruega uma das principais economias exportadoras de petróleo da Europa, este estudo analisa as interações dinâmicas destas variáveis. Empregamos três classes distintas de modelos: um modelo univariado com variáveis exógenas (SARIMAX), um modelo multivariado linear clássico (Vetor Autorregressivo - VAR) e um modelo de *Deep Learning* não-linear (Rede Recorrente LSTM em PyTorch). Os nossos resultados out-of-sample demonstram a superioridade inequívoca das abordagens multivariadas na presença de dinâmicas macrofinanceiras, com a rede LSTM a obter a maior precisão de previsão com um MAPE de apenas 2.62%, seguida de perto pelo modelo VAR (2.94%).

1 Introdução

O mercado de capitais da Noruega possui características singulares devido ao perfil económico do país. A Noruega é um dos maiores exportadores de petróleo e gás do mundo, o que torna a sua moeda (Coroa Norueguesa - NOK) uma "petro-moeda" e correlaciona intrinsecamente a performance das suas empresas cotadas (representadas no Índice de Ações) com as flutuações das *commodities* energéticas.

Neste contexto, colocamos as seguintes perguntas de investigação: 1. *Até que ponto o preço do Petróleo Brent e a taxa de câmbio USD/NOK influenciam e ajudam a prever o índice acionista norueguês?* 2. *Conseguirão as redes neuronais recorrentes (LSTM) capturar relações não-lineares complexas melhor do que os modelos econométricos clássicos (VAR e SARIMAX) neste mercado?*

O objetivo principal deste trabalho consiste em modelar e prever a série temporal mensal do Índice de Ações da Noruega de forma robusta. As principais contribuições deste estudo são: (i) comprovar empiricamente a forte ligação de curto prazo entre o petróleo e a economia financeira norueguesa, (ii) demonstrar que a modelação multivariada em primeiras diferenças dos logs é fundamental para estabilizar a variância e prever tendências macroeconómicas, e (iii) apresentar uma comparação rigorosa out-of-sample entre modelos estatísticos e algoritmos de *Deep Learning*.

O restante artigo está estruturado da seguinte forma: a Secção 2 apresenta o enquadramento teórico e empírico dos modelos; a Secção 3 detalha a arquitetura dos modelos ajustados; a Secção 4 descreve o setup experimental e a recolha dos dados; a Secção 5 analisa detalhadamente os resultados e diagnósticos; e a Secção 6 conclui o estudo apresentando as limitações e direções futuras.

2 Background Teórico

Para modelar o índice de ações da Noruega (S_t), o preço do petróleo Brent (O_t) e a taxa de câmbio USD/NOK (E_t), recorremos a três metodologias essenciais:

2.1 Modelo SARIMAX

O modelo Seasonal Autoregressive Integrated Moving Average com variáveis Exógenas (SARIMAX) é uma extensão univariada dos modelos ARIMA clássicos de Box-Jenkins. Matematicamente, para uma série y_t:

$$\phi_p(L)\Phi_P(L^s)(1-L)^d(1-L^s)^D y_t = \beta X_t + \theta_q(L)\Theta_Q(L^s)\epsilon_t \tag{1}$$

onde X_t representa a variável exógena (neste caso, o log do Petróleo Brent), L é o operador de lag ($Ly_t = y_{t-1}$), e ϵ_t representa o ruído branco. Este modelo assume linearidade e foca-se na autocorrelação própria da variável de interesse adicionando o impacto de fatores externos.

2.2 Modelo VAR (Vetor Autorregressivo)

O modelo VAR captura interdependências lineares dinâmicas entre múltiplas séries temporais. Ao contrário do SARIMAX, todas as variáveis são tratadas como endógenas. Um VAR com p lags é expresso por:

$$\mathbf{Y}_t = \mathbf{c} + \mathbf{A}_1\mathbf{Y}_{t-1} + \cdots + \mathbf{A}_p\mathbf{Y}_{t-p} + \mathbf{u}_t \tag{2}$$

onde $\mathbf{Y}_t = [\Delta \log S_t, \Delta \log E_t, \Delta \log O_t]^T$, $\mathbf{A}_i$ são matrizes de coeficientes a estimar, e $\mathbf{u}_t$ é um vetor de inovações com média zero. Caso existisse cointegração entre as variáveis em nível, a especificação correta seria o VECM (Vector Error Correction Model), que inclui um termo de correção de erro de longo prazo. No entanto, na ausência de cointegração, o VAR em diferenças é a especificação teoricamente adequada para evitar regressões espúrias.

2.3 Redes Neuronais Recorrentes (LSTM)

As redes *Long Short-Term Memory* (LSTM) são uma arquitetura de *Deep Learning* especialmente desenhada para dados sequenciais, capaz de mitigar o problema do desvanecimento do gradiente. A intuição matemática baseia-se na utilização de portas dinâmicas (*gates*): a porta de esquecimento (f_t), a porta de entrada (i_t) e a porta de saída (o_t). Estas controlam o fluxo de informação no estado da célula (c_t), permitindo que a rede retenha dependências de longo prazo não-lineares, cruciais para a volatilidade dos mercados financeiros:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \tag{3}$$

3 Modelos e Arquitetura

Os modelos finais foram ajustados no conjunto de treino seguindo critérios rigorosos de otimização:

1. **SARIMAX(1,1,1)x(0,0,0)[12]**: Determinado automaticamente por minimização do AIC via algoritmo de Stepwise. Utiliza o $\log(O_t)$ como regressor exógeno. A especificação matemática demonstra a necessidade de uma primeira diferença ($d = 1$) para estabilização da média.

2. **VAR(2)**: A seleção de lags foi feita com base no critério de informação AIC, identificando $p = 2$ lags mensais como a estrutura ótima para capturar o efeito momentum do petróleo e câmbio na bolsa norueguesa.

3. **LSTM Forecaster**: Implementado em PyTorch, a arquitetura final consiste numa camada LSTM com 8 neurónios ocultos (*hidden dimension*), uma janela temporal retroativa (*lookback*) de 3 meses, e uma camada densa de saída linear para a previsão do log-retorno. A função de

perda foi o MSE (Mean Squared Error), otimizada via Adam com taxa de aprendizagem $\alpha = 0.01$ ao longo de 150 épocas.

4 Configuração Experimental

4.1 Recolha e Alinhamento de Dados

Descarregámos 3 séries mensais da FRED no período de 1 de janeiro de 1992 a 1 de março de 2026 (411 observações completas): - **Share_Index** (S_t): SPASTT01NOM661N (OECD Stock Price Index) - **USD_NOK** (E_t): EXNOUS (USD/NOK exchange rate) - **Brent_Oil** (O_t): POILBREUSDM (Global Price of Brent Crude)

4.2 Estatísticas Descritivas

A Tabela 1 resume as estatísticas descriptivas das séries de treino (369 observações, 90% da amostra). O índice acionista apresenta assimetria positiva moderada (0.92), enquanto a taxa de câmbio e o petróleo têm curtose negativa, refletindo ciclos económicos marcados.

Variável	Média	Desvio P.	Mínimo	Máximo	Skewness
S_t (Ações)	66.80	52.02	6.73	216.43	0.92
E_t (Câmbio)	7.23	1.20	5.05	10.42	0.35
O_t (Petróleo)	53.01	32.96	10.16	133.59	0.57

Tabela 1: Estatísticas Descritivas das Variáveis em Nível (Treino).

4.3 Testes de Estacionaridade

Os testes Augmented Dickey-Fuller (ADF), Phillips-Perron (PP) e KPSS demonstraram empiricamente que todas as três séries em nível são não-estacionárias (Tabela 2). Após a aplicação da primeira diferença do logaritmo natural ($\Delta \log$), todas as séries rejeitam o teste de raiz unitária a 1%, tornando-se estacionárias ($I(1)$).

Série (Treino)	ADF (p-val)	PP (p-val)	KPSS (Stat)
S_t (Nível)	0.8481	0.8815	0.4924*
E_t (Nível)	0.9060	0.8749	0.4298*
O_t (Nível)	0.1350	0.3787	0.3471*
$\Delta \log S_t$ (Diff)	0.0000	0.0000	0.0291
$\Delta \log E_t$ (Diff)	0.0000	0.0000	0.0855
$\Delta \log O_t$ (Diff)	0.0000	0.0000	0.0451

Tabela 2: Resultados dos Testes de Raiz Unitária (Nível vs. 1ª Diferença do Log). * indica rejeição de estacionaridade a 5%.

4.4 Teste de Cointegração

O teste de Cointegração de Johansen aplicado ao vetor $[\log S_t, \log E_t, \log O_t]^T$ apresentou estatísticas de traço de 15.30 para o rank $r \leq 0$, significativamente inferior ao valor crítico de 29.80 a 95%. Assim, concluímos pela ausência de cointegração, justificando teoricamente a estimação do modelo VAR em primeiras diferenças.

5 Resultados e Análise

O período de teste (*out-of-sample*) estende-se de outubro de 2022 a março de 2026 (42 observações). A Tabela 3 exibe a comparação das métricas de erro.

Modelo	**RMSE**	**MAE**	**MAPE (%)**
SARIMAX	65.51	53.90	20.35%
VAR (2)	13.00	7.89	2.94%
LSTM (PyTorch)	**11.29**	**6.87**	**2.62%**

Tabela 3: Métricas de Erro de Previsão Out-of-Sample no Período de Teste.

A análise revela uma discrepância substancial entre o modelo univariado SARIMAX e os modelos multivariados (VAR e LSTM). O SARIMAX obteve um MAPE de 20.35%, falhando em antecipar as mudanças estruturais e acelerações pós-pandémicas e geopolíticas na cotação acionista. Isto deve-se ao facto de o SARIMAX assumir uma dinâmica linear simplificada da variável exógena.

Em contrapartida, o modelo multivariado VAR(2) obteve uma performance notável com um MAPE de apenas 2.94%, mostrando que capturar os *lags* cruzados entre o Brent e a taxa de câmbio é indispensável para modelar o mercado norueguês. A Rede LSTM obteve o melhor desempenho absoluto ($MAPE = 2.62\%$). A capacidade do modelo LSTM de reter memória de longo prazo nas suas portas e modelar interações não-lineares permitiu aproximar-se com enorme precisão dos valores reais do índice de ações no período 2022-2026.

6 Conclusão e Trabalho Futuro

Este trabalho demonstrou que a modelação macrofinanceira multivariada é altamente eficaz para prever o índice de ações da Noruega, com destaque para a superioridade da rede recorrente LSTM e do modelo VAR. A ausência de cointegração indica que estas relações residem sobretudo nas dinâmicas de curto prazo e variações percentuais (*log-returns*).

Como limitações deste trabalho, destaca-se a dependência da frequência mensal (que suaviza picos de alta frequência). Para investigações futuras, sugere-se: (i) modelar a volatilidade condicional através de uma especificação híbrida VAR-GARCH ou LSTM-GARCH para capturar clusters de volatilidade, e (ii) alargar a recolha para dados diários incluindo um índice de sentimento de notícias específicas do mercado de petróleo.